

Reconhecimento de gestos de mão com redes neurais

Relatório de andamento — 21 de setembro de 2026


Resumo

- Ensinamos dois modelos de inteligência artificial a reconhecer **18 gestos de mão** em fotos. Os dois acertam **99,8%** das fotos de pessoas que nunca viram.
- Esse número foi conferido de cinco formas diferentes e **se sustenta**. Boa parte dos poucos erros que sobram são fotos que o próprio conjunto de dados rotulou errado.
- É possível **apagar 90% de cada modelo** sem ele errar mais, e guardar o que sobra de forma mais compacta. O modelo compacto responde até **8 vezes mais rápido**.
- A melhor combinação encontrada reconhece um gesto em **0,8 milésimo de segundo**, errando praticamente o mesmo que o modelo original.
- Com **um quarto das fotos de treino** o modelo ainda erra só 0,29%. Abaixo disso a qualidade cai rápido.
- As quatro etapas previstas estão concluídas. Falta uma medição final de velocidade e a repetição de um experimento extra.

Como ler os números. Como os modelos quase não erram, comparar "99,79% com 99,80%" não diz nada. Por isso contamos **erros**: "1,5×" quer dizer "uma vez e meia os erros do modelo original". Cada experimento foi repetido 3 vezes; "±" é a variação entre as repetições.

1. O problema e os dados

O modelo recebe a foto recortada em volta da mão e responde qual dos 18 gestos ela mostra. As fotos vêm do HaGRID, um conjunto público com pessoas do mundo todo fotografadas em casa.



	quantidade
Fotos usadas	278.715, de 20.117 pessoas
Para ensinar o modelo	175.591 fotos
Para acompanhar o aprendizado	19.511 fotos
Para a prova final	83.613 fotos, de 6.044 pessoas

Regra mais importante do projeto: **uma pessoa nunca aparece em dois grupos**. Se aparecesse, o modelo poderia reconhecer a pessoa ou o quarto dela, e não o gesto. A prova final só é usada uma vez por modelo, no fim.

2. Etapa 1 — dois modelos comparados

Testamos duas "arquiteturas" conhecidas, que organizam suas camadas de jeitos opostos. Ambas partem de um modelo já treinado em fotos gerais e são ajustadas para gestos.

	ResNet-50	DenseNet-121
Acerto na prova final	99,79%	99,80%
Fotos erradas (de 83.613), nas 3 repetições	177, 165, 178	160, 167, 167
Tamanho do modelo	90 MB	27 MB
Tempo de treino	1 h 26 min	1 h 47 min

Empate em qualidade. A diferença entre os dois é menor que a variação entre repetições do mesmo modelo. A DenseNet é três vezes menor, mas mais lenta.

3. O resultado é confiável?

Um acerto tão alto levanta suspeita, então fizemos uma auditoria.

Verificação	Resultado
Alguma pessoa em dois grupos?	Nenhuma
A lista de fotos confere com os arquivos originais?	278.715 de 278.715
Fotos repetidas entre treino e prova?	Nenhuma idêntica
Se embaralharmos as respostas certas no treino, o modelo ainda acerta?	Não: 4,9%, o mesmo que chutar
E em 278.702 fotos de 19.042 pessoas que ficaram de fora do projeto?	Acerta 99,77%

Um problema real foi encontrado no conjunto de dados: algumas pessoas têm mais de um cadastro, então 87 fotos da prova (0,1%) são quase iguais a fotos do treino. Retirando da prova todas as pessoas suspeitas, no pior cenário o acerto cai de 99,79% para 99,72%. Não muda a conclusão.


Por que sobram erros? Das cerca de 170 fotos erradas, 117 são erradas pelos **dois** modelos, e em 109 delas os dois dão a mesma resposta. Olhando essas fotos, muitas estão rotuladas errado na origem. Abaixo, seis exemplos: o que o conjunto de dados diz ("marcada") e o que os dois modelos respondem.



4. Etapa 2 — deixar o modelo menor

Apagar conexões

Um modelo tem milhões de conexões, e muitas quase não influenciam a resposta. Apagamos as mais fracas e fizemos um ajuste rápido depois.



Conexões apagadas	ResNet-50	DenseNet-121	Tamanho do arquivo
50% e 70%	igual	igual	61% e 42% do original
90%	1,10×	1,03×	21%
95%	1,28×	1,19×	cerca de 15%
98%	1,90×	1,65×	cerca de 11%

Nove em cada dez conexões são dispensáveis. **Limitação importante:** apagar conexões deixa o arquivo menor, mas **não deixa o modelo mais rápido**, porque o computador faz as mesmas contas, só que com zeros.

Guardar os números com menos precisão

A segunda técnica guarda cada número do modelo em 8 bits em vez de 32. O arquivo fica com um quarto do tamanho e as contas ficam mais rápidas. Chamamos esse de **modelo compacto**.


Modelo compacto	ResNet-50	DenseNet-121
Erros, rodando no processador	1,04×	1,24×
Erros, rodando na placa de vídeo	1,01×	1,07×
Tamanho	23 MB	8 MB

Para a ResNet a compactação sai de graça. A DenseNet perde qualidade no processador.

Apagar antes ou depois de treinar?


A pedido do orientador, testamos apagar as conexões **antes** do treino. O resultado surpreendeu: a ordem importa pouco. **O que importa é quanto tempo o modelo treina depois de ter conexões apagadas.**

Com 98% da rede apagada, o que salva é treinar por mais tempo



Com 95% apagado, as três formas dão resultados parecidos. Com 98%, treinar por mais tempo depois de apagar resolve o problema nos dois modelos. Este experimento tem por enquanto uma ou duas repetições; as demais estão rodando.

5. Etapa 3 — qual versão é a melhor?



Tempo por foto (milissegundos)	ResNet-50	DenseNet-121
Processador, modelo original	10,8	16,6
Processador, modelo compacto	1,38	2,86
Placa de vídeo, precisão total	2,65	4,23
Placa de vídeo, modelo compacto	0,80	3,17
Modelo com 90% apagado (processador)	10,9	16,5


A regra de escolha foi definida **antes** de ver os resultados: entre as versões que erram no máximo 1,5× o original, vence a mais rápida na placa de vídeo.

Vencedora: ResNet-50 compacta — 0,80 ms por foto, erros 1,01×, arquivo de 24 MB.

Três aprendizados: a DenseNet faz menos contas no papel, mas é mais lenta em todas as medições; a versão compacta da DenseNet ficou mais lenta que a de meia precisão na placa de vídeo; apagar conexões não mudou a velocidade.

6. Etapa 4 — e se houvesse menos fotos?

Rotular fotos é caro. Treinamos a versão vencedora com cada vez menos fotos, sempre com a mesma prova final.



Fotos de treino	Quantidade	Erros (modelo original)	Erros (modelo compacto)
100%	175.591	referência	referência
75%	131.693	1,05×	1,07×
50%	87.798	1,28×	1,31×
25%	43.898	1,41×	1,49×
10%	17.561	2,33×	2,45×
5%	8.782	3,13×	3,30×

Com um quarto das fotos, o erro sobe 41%. O ponto de virada fica entre 25% e 10%. Mesmo com 5% das fotos o modelo acerta 99,36%. O modelo compacto acompanha o original em todos os pontos.

7. Problemas encontrados e corrigidos

- **Treinos interrompidos cedo demais.** Uma regra de "parar quando deixar de melhorar" estava cortando 13 dos 18 treinos da etapa 4 antes da fase final, que é onde o modelo mais ganha. Um ponto chegou a 277 erros em vez de 165. A regra foi retirada e os treinos foram continuados de onde pararam.
- **Compactação instável na placa de vídeo.** O ajuste da compactação usa uma amostra de 1.024 fotos. Com o método inicial, o mesmo modelo ia de 194 a 2.596 erros dependendo da amostra sorteada. Testamos quatro métodos e adotamos o mais estável, que varia de 62 a 64 erros onde o original faz 60. As 28 medições afetadas foram refeitas.
- **Memória estourada.** Esse mesmo ajuste chegou a usar 53 GB de memória e derrubou o computador duas vezes. Foi reescrito para trabalhar em partes pequenas.

8. Em andamento e pendente

Item	Situação
Repetições do experimento "antes ou depois" com 95% e 98% apagados	Rodando: 3 de 16 treinos concluídos, cerca de 21 horas restantes
Medição final de velocidade na placa de vídeo	Pendente: precisa ser feita com a tela gráfica fechada. Os tempos de placa de vídeo deste relatório são preliminares
Confirmar com o orientador dois ajustes feitos no caminho	Pendente: a retirada da parada antecipada e o critério de desempate quando duas versões têm praticamente a mesma velocidade
Artigo e pôster	A partir de 1º de novembro

9. O que já está entregue

- **Código, resultados e registros** de todos os treinos no repositório, com um comando que refaz todas as tabelas e gráficos a partir dos dados.
- **Modelos publicados** para download: os 6 modelos da etapa 1 e os 40 modelos reduzidos da etapa 2.
- **Aplicativo de demonstração** que usa a webcam: escolhe-se um dos modelos e ele reconhece o gesto feito dentro de um quadrado na tela.
- **Documentos:** metodologia, guia de reprodução, relatório da auditoria e análise dos erros.